

Laporan Teknis Komprehensif Capstone Project Data Scientist

Coding Camp 2026 powered by DBS Foundation

ID Tim Capstone Project : CC26-PSU284

Tema Capstone : Inclusive & Resilient Communities

Nama/Judul Proyek : DeepShield: Sistem Deteksi Deepfake untuk Menjaga Kepercayaan Masyarakat di Era Informasi Digital

List Anggota :

1. CDCC011D6Y2148 - Peter Taniwan - Data Scientist - **[Aktif]**
2. CDCC011D6Y1780 - Raymond Emmanuel Krista - Data Scientist - **[Aktif]**
3. CACC011D6X0900 - Rahma Aulia Putri - AI Engineer - **[Aktif]**
4. CACC299D6Y1743 - Crist Evan Lamhot Turnip - AI Engineer - **[Aktif]**
5. CFCC525D6Y0177 - Samuel Rivaldo Saragih - Full Stack Web Developer - **[Aktif]**
6. CFCC011D6X2041 - Mona Yola Lumban Raja - Full Stack Web Developer **[Aktif]**

Daftar Isi

Daftar Isi	2
1. Problem Discovery	5
1.1 Latar Belakang dan Konteks	5
1.2 Problem Statement	5
1.3 Dampak dan Urgensi.....	6
1.4 Tujuan Proyek	6
2. Pertanyaan Bisnis (<i>Business Questions</i> atau BQ)	8
BQ 1 : Keseimbangan Kelas (<i>Class Balance</i>)	8
BQ 2 — Distribusi Kecerahan (<i>Brightness</i>) & Kontras (<i>Contrast</i>)	8
BQ 3 — Anomali Distribusi Channel RGB (<i>Red, Green, and Blue</i>).....	9
3. Data Wrangling	11
3.1 Gathering Data.....	11
3.1.1 Dataset Utama	11
3.1.2 Dataset Tambahan.....	11
3.2 Assessing Data	12
3.2.1 Pengecekan Integritas (Corrupt Files & Blank Images)	12
3.2.2 Pengecekan Duplikasi Data	12
3.2.3 Pengecekan Keseimbangan Kelas	13
3.2.4 Pengecekan Geometri (Resolusi & Aspek Rasio)	13
3.3 Cleaning Data	13
3.3.1 Penanganan Data Tidak Valid	14
3.3.2 Penanganan Data Duplikat	14
3.3.3 Penanganan Keseimbangan Kelas	14
3.3.4 Penanganan Standarisasi Geometri (Resizing)	15
4. Exploratory Data Analysis (EDA).....	16
4.1 Setup dan Konfigurasi	16
4.2 Deteksi Dataset dan Inventarisasi File	16
4.3 Ekstraksi Fitur Piksel	17
4.4 Eksplorasi Data Awal (General EDA).....	17
4.4.1 Struktur Data	17

4.4.2 Kualitas File Gambar	17
4.4.3 Missing Value pada Fitur Numerik.....	17
4.4.4 Ukuran Gambar.....	17
4.4.5 Statistik Deskriptif Keseluruhan dan per Kelas	18
5. Visualisasi dan Explanatory Analysis	21
5.1 Analisis BQ 1 : Keseimbangan Kelas (Class Balance)	21
Pendekatan Analisis.....	21
Evidence dan Temuan.....	21
Interpretasi dan Kesimpulan.....	22
5.2 Analisis BQ 2 — Distribusi Kecerahan & Kontras.....	22
Pendekatan Analisis	22
Evidence dan Temuan.....	23
Interpretasi dan Kesimpulan.....	24
5.3 Analisis BQ 3 — Anomali Distribusi Channel RGB	24
Pendekatan Analisis	24
Evidence dan Temuan.....	24
Interpretasi dan Kesimpulan.....	26
5.4 Ringkasan Temuan EDA dan Visualisasi	27
6. Feature Engineering	29
6.1 Alasan dan Desain	29
6.2 Implementasi Pipeline Feature Engineering.....	29
6.3 Detail Implementasi Setiap Fitur	30
6.3.1 Sobel Edge Detection (Channel 3).....	30
6.3.2 Laplacian Filter (Channel 4).....	30
6.3.3 HSV Saturation (Channel 5)	31
6.4 Augmentasi Data	31
6.5 Arsitektur Model dengan Feature Engineering	31
6.6 Hasil dan Evaluasi Model Feature Engineering	31
6.6.1 Performa Model	32
6.6.2 Metrik Tambahan.....	32
7. A/B Testing: Model Tanpa vs Dengan Feature Engineering.....	33

7.1 Setup Eksperimen.....	33
7.2 Hipotesis Pengujian	33
7.3 Metode Pengujian.....	33
7.3.1 McNemar's Test.....	33
7.3.2 Bootstrap Confidence Interval (95%).....	34
7.4 Tabel Perbandingan Metrik	34
7.5 Hasil Uji Statistik	34
7.5.1 McNemar's Test.....	34
7.5.2 Bootstrap Confidence Interval	34
7.6 Ringkasan Hasil A/B Testing.....	35
8. Kesimpulan dan Rekomendasi Action Items.....	36
8.1 Ringkasan Temuan Keseluruhan.....	36
8.2 Rekomendasi Action Items untuk Tim AI Engineer	36
Rekomendasi 1: Gunakan Model Baseline (Tanpa FE) sebagai Production Model.....	36
Rekomendasi 2: Terapkan Augmentasi Gambar saat Pelatihan.....	36
Rekomendasi 3: Evaluasi Model dengan Metrik Komparatif.....	37
8.3 Catatan untuk Penelitian Lanjutan.....	37
9. Daftar Pustaka	38
Lampiran (Referensi Teknis)	40
A. Dataset Information	40
B. Tools dan Library yang Digunakan.....	40
C. Rumus Statistik yang Digunakan	40
D. Dokumentasi Pengerjaan Data Scientist.....	42

1. Problem Discovery

1.1 Latar Belakang dan Konteks

Teknologi deepfake merupakan gambar dan video wajah manusia yang diproduksi atau dimanipulasi menggunakan Generative Adversarial Networks (GAN). Teknologi ini telah berkembang dari alat industri kreatif menjadi ancaman keamanan informasi yang nyata. Terdapat 3 tren data terkini yang memperkuat masalah deepfake:

- **Skala penyebaran global meningkat eksponensial**

Jumlah video deepfake di internet melonjak 550% sejak 2019 menjadi 95.820 video pada akhir 2023 (Security Hero, 2023), dengan proyeksi melampaui 8 juta file pada 2025 (Guha Roy, 2025). Kerugian finansial korporasi akibat penipuan berbasis deepfake melonjak dari \$360 juta (2024) menjadi \$1,1 miliar (2025) hanya dalam satu tahun (Fortune, 2026).

- **Kemampuan deteksi manusia tidak memadai**

Meta-analisis atas 56 studi dengan 86.155 peserta membuktikan akurasi manusia mendeteksi foto wajah palsu hanya 55,54% setara tebakan acak (Diel dkk., 2024a). Lebih mengkhawatirkan, studi lanjutan menemukan fenomena *skepticism shift*: paparan konten palsu yang berulang justru merusak kepercayaan masyarakat terhadap konten asli, membuat kemampuan mengenali suara nyata anjlok dari 72,7% menjadi 64,1% (Müller dan Choong, 2026).

- **Indonesia berada di garis depan ancaman**

Komdigi mencatat 1.923 konten hoaks sepanjang 2024, memuncak pada Oktober (215 konten) bersamaan dengan musim Pilkada (Kementerian Komunikasi dan Digital, 2025). Dari sisi regulasi, UU ITE No. 1 Tahun 2024 belum memiliki ketentuan khusus tentang batas hukum pembuatan deepfake maupun kewajiban platform untuk menyaring konten sintesis secara proaktif (Irvan dan Setiawan, 2026; Putri dkk., 2025).

1.2 Problem Statement

Dari latar belakang tersebut, masyarakat Indonesia tidak memiliki akses terhadap alat deteksi deepfake yang akurat, mudah digunakan, dan gratis, sehingga rentan terhadap manipulasi informasi visual yang terus berkembang.

Seluruh rangkaian masalah dirangkum ke dalam 3 pertanyaan teknis yang ingin diselesaikan oleh tim kami yaitu:

- Seberapa tinggi keandalan model *deep learning* berbasis TensorFlow dalam membedakan gambar wajah asli dan deepfake dari dataset 2020–2026, dengan target akurasi minimal 85% pada test set independen?
- Bagaimana merancang backend Node.js/Express.js yang mampu menerima dan memproses gambar dari pengguna secara *real-time* dengan latensi di bawah 3 detik?
- Bagaimana mengintegrasikan API Generative AI untuk menghasilkan narasi penjelasan visual otomatis yang dapat dipahami pengguna non-teknis, dengan latensi respons di bawah 10 detik?

1.3 Dampak dan Urgensi

Dimensi	Fakta	Sumber
Gender	98% konten deepfake adalah pornografi non-konsensual ; 99% korbannya perempuan	Security Hero, 2023
Ekonomi	Rasio penipuan identitas digital melonjak dari <0,1% menjadi 6,5% per transaksi dalam 4 tahun	Signicat, 2025
Psikologis	Pelatihan deteksi manual meningkatkan akurasi, tetapi meningkatkan kecemasan AI (<i>AI anxiety</i>) dan menurunkan efikasi diri	Diel et al., 2024
Demokrasi	Hoaks bertema politik adalah kategori terbanyak di Indonesia (237 konten) sepanjang 2024	Komdigi, 2025

1.4 Tujuan Proyek

Berdasarkan rumusan masalah dan konteks dampak yang telah dijabarkan, proyek DeepShield menetapkan empat tujuan utama yang masing-masing dilengkapi indikator keberhasilan terukur:

No.	Tujuan	Indikator Keberhasilan
1	Akurasi Klasifikasi Tinggi	Accuracy > 85% dan F1-Score > 0,85 pada test set
2	Intepretabilitas Output	Setiap prediksi disertai <i>confidence score</i> dan narasi penjelasan visual
3	Integrasi Sistem End-to-End	Latensi deteksi < 3 detik; latensi narasi AI < 10 detik
4	Aksesibilitas Publik	Dapat diakses gratis via web browser tanpa instalasi

DeepShield dirancang sebagai solusi (*painkiller*), bukan pelengkap (vitamin) yang memindahkan beban kognitif verifikasi konten dari manusia secara manual ke sistem AI yang otomatis dan mengembalikan kepercayaan masyarakat terhadap informasi digital yang nyata dan benar.

2. Pertanyaan Bisnis (*Business Questions* atau BQ)

Sebelum memulai proses analisis data, tim mendefinisikan 3 pertanyaan bisnis utama yang akan menjadi panduan seluruh tahapan eksplorasi dan pengembangan model. Setiap pertanyaan dirumuskan menggunakan kerangka SMART agar analisis tetap terarah dan dapat dipertanggungjawabkan.

BQ 1 : Keseimbangan Kelas (*Class Balance*)

Pertanyaan
Bagaimana proporsi kelas antara gambar "Fake" dan "Real" pada dataset Deepfake tahun 2020-2026, dan apakah diperlukan penanganan imbalanced data (seperti SMOTE atau undersampling) sebelum melatih model?

Dimensi SMART	Penjelasan
S - Spesifik	Menghitung jumlah dan persentase gambar untuk kelas Fake dan Real pada setiap split (Train, Validation, Test) di dataset tahun 2020-2026.
M – Measureable (Terukur)	Rasio kelas (Fake dan Real), selisih absolut jumlah sampel, dan persentase ketidakseimbangan dalam angka pasti. Ambang batas: rasio > 1.5:1 dianggap perlu penanganan khusus.
A – Actionable (Dapat Ditindaklanjuti)	Jika kelas tidak seimbang, tim menerapkan SMOTE (Oversampling) atau random undersampling. Jika seimbang, kelas diperlakukan setara tanpa penyesuaian bobot.
R - Relevan	Ketidakseimbangan kelas yang tidak ditangani dapat membuat model bias dan cenderung memprediksi kelas mayoritas dan mengabaikan minoritas, sehingga akurasi tampak tinggi namun recall-nya buruk.
T - Terikat Waktu	Analisis terbatas pada dataset yang dikumpulkan pada tahun 2020 - 2026 sebagai titik referensi utama proyek.

BQ 2 — Distribusi Kecerahan (*Brightness*) & Kontras (*Contrast*)

Pertanyaan
Bagaimana perbedaan distribusi tingkat pencahayaan (brightness) dan kontras (contrast) antara gambar "Fake" dan "Real" pada dataset tahun 2020-2026, dan apakah perbedaan tersebut memerlukan penerapan teknik augmentasi/manipulasi data gambar (seperti color jittering) selama pelatihan model?

Dimensi SMART	Penjelasan
S - Spesifik	Membandingkan nilai rata-rata kecerahan grayscale (brightness_mean) dan standar deviasi grayscale sebagai nilai estimasi standar deviasi kontras (contrast_std) antara kelas Fake dan Real.
M – Measureable (Terukur)	Perbedaan dievaluasi secara statistik menggunakan uji Mann-Whitney U (p-value) dan ukuran efek Cohen's d. Efek $d > 0.5$ dianggap signifikan secara praktis.
A – Actionable (Dapat Ditindaklanjuti)	Jika distribusi keduanya berbeda secara signifikan, perlu menerapkan augmentasi color jittering (brightness, contrast) agar model tidak belajar dari artefak pencahayaan yang bias terhadap kelas tertentu.
R - Relevan	Perbedaan sistematis pada pencahayaan dan kontras bisa menjadi "jalan pintas" yang dipelajari model bukan karena perbedaan wajah asli vs palsu, melainkan karena perbedaan kondisi pencahayaan. Ini menciptakan model yang bias dan tidak reliabilitas di data real lainnya.
T - Terikat Waktu	Analisis berfokus pada data tahun 2020-2026; kondisi distribusi mungkin berbeda pada dataset tahun lain.

BQ 3 — Anomali Distribusi Channel RGB (*Red, Green, and Blue*)

Pertanyaan
Apakah terdapat anomali atau pergeseran distribusi nilai intensitas warna pada channel RGB (Red, Green, Blue) gambar "Fake" dibandingkan "Real" di dataset tahun 2020-2026, yang dapat dimanfaatkan untuk menentukan arsitektur layer (seperti Channel Attention) pada model pendeteksi?

Dimensi SMART	Penjelasan
S - Spesifik	Membandingkan distribusi nilai rata-rata channel R, G, dan B (r_mean, g_mean, b_mean) antara kelas Fake dan Real, serta mengidentifikasi channel mana yang menunjukkan perbedaan distribusi terbesar.
M – Measureable (Terukur)	Perbedaan dievaluasi dengan KDE overlay, box plot, dan Cohen's d per channel. Channel dengan $ d > 0.2$ dianggap memiliki sinyal yang relevan untuk digunakan model.

A - Actionable (Dapat Ditindaklanjuti)	Jika ada channel yang menunjukkan distribusi konsisten, tim ML mempertimbangkan penggunaan arsitektur Channel Attention (seperti SE-Net atau CBAM) untuk memberi bobot lebih pada channel yang paling informatif.
R - Relevan	Proses pembuatan wajah deepfake sering meninggalkan jejak artefak (buatan komputer) pada channel warna tertentu, terutama pada area kulit wajah. Mengidentifikasi channel informatif bisa menjadi keunggulan arsitektur model.
T - Terikat Waktu	Analisis berfokus pada data tahun 2020-2026; pola artefak GAN bisa berbeda seiring evolusi teknologi deepfake.

3. Data Wrangling

Proses Data Wrangling merupakan fondasi dari seluruh pipeline analisis data dan persiapan untuk melakukan pemodelan. Tanpa data yang bersih dan terstruktur, hasil analisis dapat keliru dan akurasi model tidak dapat dioptimalkan. Pada tahap ini dijalankan tiga tahapan utama Data Wrangling, yaitu Gathering Data, Assessing Data, dan Cleaning Data.

3.1 Gathering Data

Proses Gathering data pada notebook ini terdiri dari dua bagian, yaitu Dataset Utama yang terdiri dari 1 Dataset Kaggle dan Dataset tambahan yang terdiri dari 4 Dataset Kaggle.

3.1.1 Dataset Utama

Dataset utama yang digunakan adalah dataset deepfake wajah manusia dari [Kaggle](#) (manjilkarki/deepfake-and-real-images) dengan struktur direktori tiga split yang sudah tersedia seperti berikut :

```
DATA_DIR = "/kaggle/input/datasets/manjilkarki/deepfake-and-real-images/Dataset"
train_dir = os.path.join(DATA_DIR, "Train")
val_dir = os.path.join(DATA_DIR, "Validation")
test_dir = os.path.join(DATA_DIR, "Test")
```

Jumlah gambar per split dihitung menggunakan fungsi `count_total_images()` yang menelusuri semua subdirektori kelas:

Split Dataset	Jumlah Gambar	Proporsi	Keterangan
Train	140.002	73,5%	Data utama untuk pelatihan model
Validation	39.428	20,7%	Data untuk monitoring performa saat training
Test	10.905	5,8%	Data independen untuk evaluasi akhir
Total	190.335	100 %	Keseluruhan dataset utama yang dianalisis

3.1.2 Dataset Tambahan

Untuk meningkatkan performa model, ditambahkan empat dataset deepfake dari Kaggle dengan total ±200.000 gambar. Keempat sumber dataset tersebut adalah:

- [chuneeb/deepfake-detection-dataset-2026](#)

- [saurabhbagchi/deepfake-image-detection](https://github.com/saurabhbagchi/deepfake-image-detection)
- [xhlulu/140k-real-and-fake-faces \(direktori real vs fake/\)](https://github.com/xhlulu/140k-real-and-fake-faces)
- [prithivsakthiur/deepfake-vs-real-60k](https://github.com/prithivsakthiur/deepfake-vs-real-60k)

Proses gathering dataset tambahan menggunakan fungsi `gather_extra_images()` yang mendukung struktur folder flat maupun bersarang. Label (Real/Fake) dideteksi otomatis berdasarkan nama folder induk menggunakan pendekatan keyword matching. Selanjutnya dataset tambahan dibagi menjadi 3 Split yaitu Train, Validation, dan Test sesuai dengan proporsi split pada dataset utama. Sehingga pada akhir Dataset yang terkumpul adalah sebagai berikut :

Sumber	Train	Validation	Test	Total
Dataset Utama	140.002	39.428	10.905	190.335
Dataset Tambahan	145.569	40.997	11.488	198.054
Total	285.571	80.425	22.393	388.389

3.2 Assessing Data

Tahap assessing meliputi evaluasi menyeluruh terhadap kualitas dan karakteristik dataset gabungan. Enam aspek utama yang diperiksa:

3.2.1 Pengecekan Integritas (Corrupt Files & Blank Images)

Setiap gambar diperiksa menggunakan `PIL.Image`. Gambar dianggap "blank" jika variance pikselnya < 5 (hampir seragam warnanya). Gambar corrupt adalah gambar yang gagal dibuka sama sekali.

```
def is_blank(img_arr, thresh_var=5):
    return img_arr.var() < thresh_var
```

Hasil Pengecekan Integritas
• Corrupt files: 0 • Blank images: 0 Kesimpulan: Seluruh gambar dalam dataset dapat dibaca dengan normal sehingga tidak perlu dilakukan penanganan apapun.

3.2.2 Pengecekan Duplikasi Data

Deteksi duplikasi dilakukan menggunakan hashing MD5 pada konten biner setiap file gambar. Pendekatan ini memastikan deteksi duplikat yang exact (byte-by-byte identical), termasuk deteksi gambar yang sama yang mungkin muncul di beberapa dataset berbeda.

```
def file_hash(path):
    h = hashlib.md5()
    with open(path, "rb") as f:
        for chunk in iter(lambda: f.read(8192), b''): h.update(chunk)
    return h.hexdigest()
```

Hasil Pengecekan Duplikasi				
Jumlah	pasangan	duplikat	(exact):	17.322
Kesimpulan: Terdapat gambar dalam dataset yang duplikat sehingga diperlukan penghapusan gambar yang duplikat.				

3.2.3 Pengecekan Keseimbangan Kelas

Distribusi kelas dihitung menggunakan `collections.Counter` berdasarkan nama folder (Fake/Real) sebagai label. Ini memvalidasi bahwa label sudah tertanam dalam struktur direktori dataset.

Kelas	Jumlah	Proporsi
Real	194.277	50.1 %
Fake	194.112	49.9 %
Total	388.389	100 %

Kesimpulan: Distribusi kelas sangat seimbang mendekati 50 / 50 sehingga tidak diperlukan penanganan resampling seperti oversampling maupun undersampling.

3.2.4 Pengecekan Geometri (Resolusi & Aspek Rasio)

Seluruh gambar dari `all_paths` diperiksa dimensinya menggunakan `PIL.Image` untuk mengetahui variasi resolusi dan aspek ratio yang ada di dataset gabungan.

Parameter	Nilai
Width (Min/Max)	183 / 8.495 px
Height (Min/Max)	135 / 7.091 px
Aspect Ratio (Min/Max)	0,3278 / 2,9979

Kesimpulan: Variasi resolusi yang sangat besar antar gambar, mulai dari 183px hingga 8.495px untuk lebar dan 135px hingga 7.091px untuk tinggi serta aspek ratio yang bervariasi dari portrait hingga landscape. Oleh karena itu, diperlukan penanganan standarisasi resolusi pada tahap packaging dengan mereseize seluruh gambar ke ukuran yang seragam.

3.3 Cleaning Data

Berdasarkan hasil penilaian data, terdapat empat jenis cleaning dilakukan, yaitu :

3.3.1 Penanganan Data Tidak Valid

Semua path gambar yang masuk daftar corrupt atau blank dikeluarkan dari valid_paths. Mengingat tidak ada gambar yang korup, tahap ini mengkonfirmasi bahwa seluruh dataset valid.

```
valid_paths = [p for p in all_paths if p not in corrupt_files and p not in blank_files]
```

Hasil:

- Data sebelum cleaning : 388.389
- Corrupt + blank yang dihapus: 0
- Data setelah cleaning : 388.389

Kesimpulan: Tidak ada gambar yang perlu dihapus karena seluruh dataset lolos pengecekan integritas. Tahap ini mengkonfirmasi bahwa semua gambar dari kelima dataset dapat dibaca dengan normal dan tidak mengandung data kosong.

3.3.2 Penanganan Data Duplikat

Data duplikat yang terdeteksi pada tahap assessing dihapus dari valid_paths. Ini khususnya penting karena ada kemungkinan tumpang tindih gambar antar keempat dataset tambahan.

```
valid_paths = [p for p in all_paths if p not in corrupt_files and p not in blank_files]
```

Hasil:

- Jumlah duplikasi terdeteksi : 17.322
- Gambar yang dihapus : 17.313
- Data setelah cleaning : 371.076

Kesimpulan: Sebanyak 17.313 gambar duplikat berhasil dihapus dari dataset. Selisih 9 antara pasangan duplikat (17.322) dan gambar dihapus (17.313) terjadi karena beberapa gambar muncul lebih dari dua kali sehingga satu file bisa menjadi duplikat dari beberapa file sekaligus. Penanganan ini memastikan tidak ada data leakage antar split Train/Validation/Test.

3.3.3 Penanganan Keseimbangan Kelas

Berdasarkan hasil penilaian, distribusi kelas sudah sangat seimbang (~50/50) sehingga tidak diperlukan penanganan khusus seperti oversampling (SMOTE) maupun undersampling.

Hasil :

Kelas	Jumlah	Proporsi
Real	176.982	47,7%
Fake	194.094	52,3%
Total	371.076	100 %

Kesimpulan: Keseimbangan kelas Fake dan Real sebesar 52,3%:47,7% masih dalam batas toleransi keseimbangan kelas yang wajar untuk pelatihan model deep learning sehingga tidak diperlukan teknik resampling tambahan.

3.3.4 Penanganan Standarisasi Geometri (Resizing)

Berdasarkan hasil pengecekan geometri, ditemukan variasi resolusi yang sangat besar antar gambar (183px hingga 8.495px). Standarisasi dilakukan pada tahap packaging dengan mereshize seluruh gambar ke ukuran seragam 256×256 piksel menggunakan metode LANCZOS sebelum dikemas ke ZIP:

```
img.thumbnail((256, 256), Image.LANCZOS)
img.save(buf, format="JPEG", quality=85, optimize=True)
```

Hasil:

- Resolusi sebelum : Bervariasi
- Resolusi sesudah : 256×256 piksel

Kesimpulan: Seluruh 371.076 gambar berhasil distandarisasi ke resolusi seragam 256×256 piksel sehingga memudahkan tim AI Engineer untuk melakukan pemodelan *Deep Learning*.

Kesimpulan Data Wrangling

Dataset telah bersih, terstruktur, dan siap digunakan untuk analisis dan proses pelatihan model deep learning. Proses wrangling berhasil menggabungkan dataset awal (190.335 gambar) dengan empat dataset tambahan (198.054 gambar) menjadi satu dataset terpadu dengan struktur tiga-split (Train/Validation/Test) yang konsisten. Setelah itu dataset gabungan sudah berhasil dibersihkan melalui 4 Aspek yaitu, Integritas, Deduplikasi, Keseimbangan Kelas, dan Geometri sehingga menghasilkan **371.076** gambar yang sudah bersih dan siap diproses lebih lanjut.

4. Exploratory Data Analysis (EDA)

Sebelum menjawab pertanyaan bisnis, notebook melakukan eksplorasi data analysis (EDA) untuk memahami kondisi dasar dataset. Tahap ini mencakup pemeriksaan struktur tabel, kualitas file, missing value, keseragaman ukuran gambar, dan statistik deskriptif. Pemahaman menyeluruh di tahap ini memastikan bahwa seluruh analisis lanjutan dilakukan dengan data yang valid dan terpercaya.

4.1 Setup dan Konfigurasi

EDA menggunakan konfigurasi berikut untuk memastikan konsistensi dan reproduksibilitas:

Parameter	Nilai	Keterangan
FEATURE_THUMB_SIZE	128x128	Thumbnail sebelum konversi NumPy (efisiensi ~30x)
PLOT_SAMPLE_SIZE	12.000	Sampel untuk visualisasi distribusi
RGB_SAMPLE_SIZE	15.000	Sampel untuk analisis channel RGB
N_WORKERS	min(CPU, 8)	Worker paralel untuk ekstraksi fitur
RANDOM_STATE	42	Seed untuk reproduksibilitas

Palet warna konsisten digunakan di seluruh visualisasi: Merah (#E74C3C) untuk kelas Fake dan Hijau (#2ECC71) untuk kelas Real.

4.2 Deteksi Dataset dan Inventarisasi File

Fungsi `find_dataset_root()` mencari direktori yang memiliki struktur Train/Validation/Test dengan subclass Fake/Real. Setelah root dataset ditemukan, inventory dibuat untuk semua file .jpg dan .jpeg:

Split	Kelas	Jumlah File
Train	Fake	142.910
Train	Real	125.749
Validation	Fake	40.035
Validation	Real	39.989
Test	Fake	11.149
Test	Real	11.244
TOTAL	-	371.076

4.3 Ekstraksi Fitur Piksel

Fitur piksel diekstrak dari setiap gambar menggunakan `ProcessPoolExecutor` untuk pemrosesan paralel. Thumbnail 128x128 dibuat terlebih dahulu sebelum konversi ke NumPy array untuk efisiensi komputasi.

Fitur yang diekstrak per gambar mencakup:

- Metadata dimensi: `width`, `height`, `aspect_ratio`, `megapixels`
- Kecerahan: `brightness_mean` (rata-rata grayscale), `brightness_median`
- Kontras: `contrast_std` (standar deviasi grayscale sebagai proksi kontras)
- Warna RGB: `r_mean`, `g_mean`, `b_mean` dan `r_std`, `g_std`, `b_std`
- Hash dan flag kualitas: `image_hash`, `is_corrupt` untuk gambar yang tidak dapat dibaca

4.4 Eksplorasi Data Awal (General EDA)

Setelah ekstraksi fitur, EDA awal meninjau kondisi dataset secara keseluruhan dalam lima aspek utama.

4.4.1 Struktur Data

Tabel fitur hasil ekstraksi terdiri dari 371.076 baris dan 22 kolom. Fitur numerik bertipe `int64` atau `float64`, sedangkan kolom kategorikal bertipe `object` atau `Categorical`. Tidak ada indikasi tipe data yang tidak sesuai, sehingga data siap digunakan untuk analisis statistik dan visualisasi tanpa memerlukan tahap konversi tipe data tambahan

4.4.2 Kualitas File Gambar

Metrik Kualitas	Nilai
Total gambar diproses	371.076
Gambar terbaca normal	371.076 (100%)
Gambar korup/error	0 (0.00%)

Seluruh 371.076 gambar berhasil dibaca tanpa satu pun yang corrupt, sehingga tidak ada data yang perlu dikeluarkan dari analisis. Kualitas file yang sempurna ini mengkonfirmasi bahwa dataset sepenuhnya bersih dan siap untuk analisis lebih lanjut.

4.4.3 Missing Value pada Fitur Numerik

Tidak ditemukan nilai kosong pada kesembilan fitur numerik yang diperiksa (`brightness_mean`, `brightness_median`, `contrast_std`, `r_mean`, `g_mean`, `b_mean`, `r_std`, `g_std`, `b_std`). Seluruh 371.076 gambar menghasilkan nilai piksel yang valid, sehingga analisis selanjutnya dapat langsung dilakukan tanpa perlu penanganan missing value.

4.4.4 Ukuran Gambar

Ukuran gambar dalam dataset tidak sepenuhnya seragam. Sebanyak 343.130 gambar (92,47%) memiliki dimensi 256×256 piksel, namun terdapat variasi lebar pada 7,53% gambar lainnya seperti hasil pada tabel berikut ini :

Width	Height	Jumlah Gambar	Persentase
256	256	343130	92,47 %
165	256	8561	2,3 %
205	256	8065	2,1 %
192	256	1803	0,48 %
168	256	1677	0,45 %
212	256	985	0,26 %
211	256	948	0,25 %
182	256	691	0,18 %
191	256	456	0,12 %
185	256	365	0,09 %

4.4.5 Statistik Deskriptif Keseluruhan dan per Kelas

Secara keseluruhan, statistik deskriptif dari dataset gambar deepfake dan real dapat dilihat pada tabel berikut :

Fitur	Count	Mean	Std	Min	25%	Median	75%	Max
brightness_mean	371,076	109.2664	31.5174	1.6954	88.0811	108.9147	129.8137	248.5000
brightness_median	371,076	106.3692	41.1324	0.0000	78.1165	106.4155	133.5176	255.0000
contrast_std	371,076	55.8612	12.4858	4.5300	47.7120	55.7928	64.0229	118.9240
r_mean	371,076	126.0141	33.5637	1.4478	103.7969	126.3142	148.3636	251.7604
g_mean	371,076	103.8230	32.0979	0.6408	81.9781	103.2938	124.7056	250.5419
b_mean	371,076	93.3692	33.3295	1.3163	69.9462	91.7670	114.8481	246.3292
r_std	371,076	61.9209	13.4597	2.1947	53.0509	62.1135	71.0285	118.8739
g_std	371,076	55.6658	13.0989	1.0502	47.0557	55.4625	64.1576	118.6863
b_std	371,076	54.1480	14.5484	1.4275	44.5075	53.8073	63.6014	120.3413

Statistik deskriptif keseluruhan menunjukkan nilai rata-rata brightness_mean sekitar 109 dan standar deviasi sekitar 32, sementara nilai rata-rata contrast_std sekitar 56 dengan standar deviasi 12, yang mencerminkan variasi gelap-terang yang moderat di seluruh dataset. Channel Red memiliki rata-rata tertinggi (≈ 126) dibandingkan Green (≈ 104) dan Blue (≈ 93), yang merupakan pola umum pada gambar wajah dan akan menjadi fokus utama pada analisis BQ 3. Secara keseluruhan, nilai standar deviasi yang lebih kecil dari nilai mean menunjukkan bahwa tidak ada variasi ekstrem yang dominan sehingga nilai mean masih cukup representatif sebagai ukuran pemusatan data dibanding median.

Sedangkan untuk statistika deskriptif dari dataset gambar per kelas-nya dapat dilihat pada table berikut :

Fitur	Fake (194.094 gambar)				
	Mean	Std	Median	Min	Max
brightness_mean	108.6671	31.5014	108.4163	1.6954	248.5000
brightness_median	105.6501	41.0116	105.9265	0.0000	255.0000
contrast_std	55.3888	12.7407	55.2363	4.5300	116.1788
r_mean	125.4611	33.4919	125.8308	1.4478	251.7604
g_mean	103.1913	32.0399	102.6592	0.6408	248.3012
b_mean	92.8470	33.4283	91.1996	1.3163	246.3292
r_std	61.5294	13.7610	61.7163	2.1947	117.2955
g_std	55.0641	13.3550	54.7772	1.0502	116.5891
b_std	53.2640	14.7597	52.7400	1.4275	114.8799

Fitur	Real (176.982 gambar)				
	Mean	Std	Median	Min	Max
brightness_mean	109.9236	31.5220	109.4843	3.2439	245.2237
brightness_median	107.1578	41.2503	106.9903	0.0000	255.0000
contrast_std	56.3793	12.1791	56.3565	4.6571	118.9240

r_mean	126.6206	33.6318	126.8510	3.9248	250.7137
g_mean	104.5180	32.1630	104.0010	0.9870	250.5419
b_mean	93.9419	33.2115	92.3574	1.6661	241.3054
r_std	62.3502	13.1079	62.5476	4.8052	118.8739
g_std	56.3256	12.7795	56.1882	2.3508	118.6863
b_std	55.1175	14.2501	54.9588	2.4386	120.3413

Perbandingan statistik deskriptif awal antara kelas Fake dan Real menunjukkan perbedaan yang kecil di seluruh fitur numerik, dengan kelas Real secara konsisten memiliki nilai rata-rata yang sedikit lebih tinggi daripada Fake di semua channel warna serta brightness dan contrast. Pola ini menjadi indikasi awal bahwa gambar Real cenderung sedikit lebih cerah dan lebih berwarna dibanding gambar Fake, meskipun perlu diuji lebih lanjut secara statistik untuk menilai seberapa bermakna perbedaan tersebut secara praktis.

5. Visualisasi dan Explanatory Analysis

Bagian ini menjawab tiga pertanyaan bisnis (BQ) menggunakan analisis visual dan statistik terhadap 371.076 gambar dataset gabungan tahun 2020–2026. Setiap analisis menyajikan metode yang digunakan, temuan kuantitatif, dan implikasi teknis langsung bagi pengembangan model.

5.1 Analisis BQ 1 : Keseimbangan Kelas (Class Balance)

Pendekatan Analisis

Distribusi kelas dianalisis menggunakan bar chart keseluruhan dan grouped bar chart per split, dilengkapi tiga metrik kuantitatif: selisih absolut, persentase selisih, dan rasio kelas mayoritas:minoritas. Ambang batas yang ditetapkan: rasio > 1,5:1 memerlukan penanganan *resampling* aktif.

Evidence dan Temuan


Distribusi Kelas Keseluruhan

Kelas	Jumlah	Persentase
Fake	194.094	52,31%
Real	176.982	47,69%
Total	371.076	100%

Selisih absolut: 17.112 gambar (4,62%) → Rasio: 1,097:1 (masih di bawah ambang 1,5:1).

Distribusi per Split

Split	Fake	Real	Selisih Proporsi	Status
Train	142.910 (53,19%)	125.749 (46,81%)	6,38%	Perlu Perhatian
Validation	40.035 (50,03%)	39.989 (49,97%)	0,06%	Seimbang
Test	11.149 (49,79%)	11.244 (50,21%)	0,42%	Seimbang



Grouped bar chart menampilkan batang Fake pada split Train jauh lebih tinggi dari Real, sementara batang Validation dan Test hampir identik.

Interpretasi dan Kesimpulan

Temuan BQ 1: Distribusi global masih aman (rasio 1,097:1), namun ketimpangan terkonsentrasi di split Train (selisih 17.161 gambar / 6,38%). Model belajar dari distribusi yang berbeda dengan yang dievaluasinya — kondisi ini berpotensi mendorong model lebih sering memprediksi kelas Fake.

Implikasi Teknis

- Terapkan class weight pada loss function untuk memberi bobot lebih tinggi pada kelas Real saat pelatihan — tanpa mengubah jumlah data.
- Gunakan F1-Score (macro) dan AUC-ROC sebagai metrik utama, bukan sekadar akurasi.
- Pertahankan split Validation dan Test apa adanya sebagai tolok ukur evaluasi yang tidak bias.



5.2 Analisis BQ 2 — Distribusi Kecerahan & Kontras

Pendekatan Analisis

Fitur `brightness_mean` dan `contrast_std` dibandingkan menggunakan histogram density, boxplot, dan statistik deskriptif per kelas. Signifikansi perbedaan diuji dengan Mann-Whitney U (robust terhadap distribusi non-normal), dilengkapi Cohen's d sebagai ukuran efek praktis — karena dengan 371.076 sampel, p-value hampir selalu kecil meski perbedaannya minimal.

Evidence dan Temuan

Fitur	Fake (Mean)	Real (Mean)	Selisih Mean	Cohen's d	Ukuran Efek	p-value	Signifikansi
Brightness Mean	108,67	109,92	1,26	-0,04	Sangat Kecil	< 0.05	Signifikan
Contrast Std	55,39	56,38	0,99	-0,079	Sangat Kecil	< 0.05	Signifikan



Histogram brightness dan contrast menampilkan dua kurva yang sangat bertumpang tindih dengan kurva Real sedikit bergeser ke kanan, namun tidak ada nilai ambang yang bisa

memisahkan kedua kelas. Boxplot mengonfirmasi median Real sedikit lebih tinggi (brightness: ~109 vs ~108), tetapi IQR kedua kelas hampir identik.

Interpretasi dan Kesimpulan

Temuan BQ 2: Perbedaan brightness dan contrast signifikan secara statistik ($p < 0,05$) tetapi tidak bermakna secara praktis ($|d| < 0,2$). Gambar Real cenderung sedikit lebih terang dan kontras — artefak proses GAN yang menghasilkan rentang kecerahan lebih homogen dari foto asli. Namun selisihnya terlalu kecil untuk dijadikan fitur pembeda utama.

Implikasi Teknis:

- Terapkan normalisasi gambar (*rescaling* [0,1]) sebelum pelatihan agar bias kecil ini tidak diperkuat model.
- Tambahkan augmentasi ColorJitter (brightness=0.3, contrast=0.3, saturation=0.1, hue=0.05) agar model robust terhadap variasi pencahayaan, bukan untuk merespons perbedaan yang besar.

5.3 Analisis BQ 3 — Anomali Distribusi Channel RGB



Pendekatan Analisis


Distribusi intensitas channel R, G, dan B dianalisis menggunakan KDE overlay per channel, tabel mean dan standar deviasi per kelas, serta Cohen's d per channel. Tujuannya: mengidentifikasi "sidik jari" artefak GAN pada level warna dan menentukan channel mana yang paling layak dieksploitasi oleh arsitektur model.

Evidence dan Temuan

Channel	Fake (Mean)	Real (Mean)	Selisih Mean	Cohen's d	Ukuran Efek	p-value	Signifikansi
Red (R)	125,46	126,62	1,16	-0,035	Kecil	< 0.05	Signifikan
Green (G)	103,19	104,52	1,34	-0,042	Sangat Kecil (terbesar)	< 0.05	Signifikan
Blue (B)	92,85	93,94	1,09	-0,033	Sangat Kecil	< 0.05	Signifikan

Semua channel signifikan secara statistik ($p < 0,05$, Mann-Whitney U).





KDE plot ketiga channel menunjukkan kurva Real secara seragam bergeser ke kanan dibandingkan Fake dengan arah perbedaan yang konsisten di seluruh channel. Pergeseran paling terbaca secara visual terjadi pada channel Green. Nilai negatif Cohen's d pada ketiga channel mengonfirmasi arah yang identik: Fake selalu lebih rendah dari Real.

Interpretasi dan Kesimpulan

Temuan BQ 3: Ketiga channel menunjukkan pola artefak GAN yang konsisten dan searah serta deepfake secara sistematis menghasilkan intensitas warna lebih redup dari foto asli. Channel Green adalah yang paling informatif ($|d| = 0,042$), diikuti Red (0,035) dan Blue (0,033). Konsistensi arah ini bukan noise acak tetapi ada sinyal sistematis yang dapat dipelajari model secara adaptif.

Channel Green lebih sensitif karena berkontribusi besar pada persepsi naturalness warna kulit manusia, sementara channel Blue lebih mudah direplikasi GAN karena nilainya relatif homogen di berbagai kondisi pencahayaan.

Implikasi Teknis:

- Pertimbangkan integrasi SE Block atau CBAM (*Channel Attention*) setelah 2–3 layer konvolusi awal agar model belajar otomatis memberi bobot lebih pada channel Green dan Red.
- Gunakan channel-wise normalization ImageNet: mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225] sebagai standar preprocessing.

5.4 Ringkasan Temuan EDA dan Visualisasi

BQ	Pertanyaan	Temuan Utama	Nilai Kunci	Tindak Lanjut
BQ 1	Keseimbangan Kelas	KelasKetimpangan di split Train; Validation & Test sudah 50:50	Rasio Train: 1,136:1; selisih 6,38%	Terapkan class weight
BQ 2	Brightness & Contrast	Perbedaan sangat kecil secara praktis; GAN menghasilkan kecerahan lebih homogen	Cohen's d: -0,040 / -0,079	Normalisasi + ColorJitter
BQ 3	Distribusi Channel RGB	Arah artefak GAN konsisten; channel Green paling informatif	Cohen's d Green: -0,042	Channel Attention (SE Block/CBAM)

Catatan penting: Tidak ada satu pun fitur piksel tunggal yang cukup kuat berdiri sendiri sebagai pembeda Fake vs Real karena seluruh Cohen's d berada di bawah 0,2. Ini menegaskan bahwa model CNN yang dalam adalah pilihan arsitektur yang tepat, karena yang dibutuhkan adalah pemahaman terhadap representasi struktural wajah secara holistik, bukan hafalan bias statistik permukaan.

6. Feature Engineering

Feature Engineering adalah proses penambahan representasi visual di luar 3 channel RGB standar untuk memperkaya informasi yang tersedia bagi model CNN. Tujuannya adalah memungkinkan model mendeteksi artefak GAN yang lebih tersembunyi seperti pola tepi, ketajaman, dan distribusi saturasi warna.

6.1 Alasan dan Desain

Berdasarkan temuan EDA, proses generasi GAN meninggalkan jejak di level piksel yang mungkin tidak terlihat secara visual namun dapat dideteksi secara komputasional. Feature engineering dirancang untuk mengekspos tiga jenis "sidik jari" ini:

Channel	Nama Fitur	Deskripsi	Alasan
Ch 0-2	RGB Original	Warna asli gambar (dinormalisasi ke [0,1])	Informasi warna dasar
Ch 3	Sobel Edge	Deteksi tepi/kontur menggunakan gradien	GAN sering menghasilkan tepi yang tidak natural
Ch 4	Laplacian Filter	Mengukur ketajaman atau blur pada gambar	Area blur di deepfake berbeda dari foto nyata
Ch 5	HSV Saturation	Saturasi warna dari ruang warna HSV	Kulit manusia memiliki pola saturasi khas

6.2 Implementasi Pipeline Feature Engineering

Semua fitur diimplementasikan sebagai operasi TensorFlow yang sepenuhnya dapat di-GPU-accelerate, sehingga tidak menambah bottleneck pada pipeline data:

```
def extract_features(image, label):
    image = tf.cast(image, tf.float32) / 255.0 # Normalisasi ke [0,1]
    gray = tf.image.rgb_to_grayscale(image) # Konversi grayscale

    # Fitur 1: Sobel Edge Detection
    sobel = tf.image.sobel_edges(gray)
    sobel_mag = tf.sqrt(sobel_x**2 + sobel_y**2)
    sobel_mag = sobel_mag / (tf.reduce_max(...) + 1e-7) # Normalisasi per-gambar

    # Fitur 2: Laplacian Filter
```

```
kernel = [[0,1,0],[1,-4,1],[0,1,0]] # Kernel Laplacian 3x3
laplacian = tf.abs(tf.nn.conv2d(gray, kernel, ...))

# Fitur 3: HSV Saturation
saturation = tf.image.rgb_to_hsv(image)[:,:,:1:2]

return tf.concat([image, sobel_mag, laplacian, saturation], axis=-1), label
```

Hasil akhir: setiap gambar menjadi tensor berukuran (batch, 160, 160, 6) dari 3 channel RGB menjadi 6 channel dengan tambahan informasi edge, sharpness, dan saturation.

6.3 Detail Implementasi Setiap Fitur

6.3.1 Sobel Edge Detection (Channel 3)

Sobel edge detection menghitung gradien gambar grayscale pada arah horizontal (x) dan vertikal (y). Magnitude gradien dihitung menggunakan kombinasi Sobel-x dan Sobel-y.

- Menggunakan `tf.image.sobel_edges()` yaitu fungsi bawaan TensorFlow yang dioptimalkan
- Normalisasi per-gambar menggunakan `reduce_max` untuk menghindari saturasi nilai
- Nilai tinggi = area tepi/kontur; nilai rendah = area datar

Sobel edge digunakan dikarenakan pada proses generasi GAN terkadang menghasilkan tepi wajah yang tidak sepenuhnya natural ada "kebocoran" berlebihan pada area kontur yang dapat terdeteksi oleh filter Sobel.

6.3.2 Laplacian Filter (Channel 4)

Filter Laplacian mengukur laju perubahan intensitas piksel. Area dengan nilai tinggi menunjukkan perubahan intensitas yang tajam dan detail. Nilai rendah menunjukkan area yang smooth atau blur.

- Kernel 3x3 standar: `[[0,1,0],[1,-4,1],[0,1,0]]`
- Padding SAME memastikan output shape sama dengan input
- `tf.abs()` diperlukan karena Laplacian bisa negatif

Laplacian digunakan karena dalam Deepfake GAN sering menghasilkan gambar dengan pola blur yang berbeda dari foto nyata — terutama di area kulit yang "terlalu halus" atau rambut yang "terlalu tajam".

6.3.3 HSV Saturation (Channel 5)

Saturasi HSV mengukur "kemurnian" warna dan seberapa jauh warna tersebut dari abu-abu. Warna kulit manusia memiliki distribusi saturasi yang khas yang cenderung sulit direplikasi sempurna oleh GAN.

- `tf.image.rgb_to_hsv()` mengkonversi gambar ke ruang warna Hue-Saturation-Value
- Hanya channel Saturation (index 1) yang diambil sebagai fitur
- Area warna hangat (kulit, bibir) memiliki saturasi tinggi; background abu-abu memiliki saturasi rendah

6.4 Augmentasi Data

Dikombinasikan dengan feature engineering, pipeline augmentasi data diterapkan untuk meningkatkan generalisasi model:

```
data_augmentation = Sequential([
    layers.RandomRotation(0.05, seed=42),
    layers.RandomZoom(0.05, seed=42),
    layers.RandomFlip("horizontal", seed=42),
    layers.RandomGaussianBlur(0.05, seed=42)
])
```

6.5 Arsitektur Model dengan Feature Engineering

Model yang dibangun adalah Custom ResNet dengan Residual Blocks untuk memproses input 6-channel:

Komponen	Spesifikasi
Input Shape	(160, 160, 6) — RGB + 3 fitur tambahan
Arsitektur	Custom ResNet dengan Residual Blocks
Training Loop	Custom loop dengan <code>tf.GradientTape</code>
Loss Function	Binary Crossentropy dengan <code>label_smoothing=0.1</code>
Optimizer	Adam dengan learning rate adaptif
Regularisasi	L2 weight decay ($1e-4$) + Dropout
Callbacks	EarlyStopping, ReduceLROnPlateau, ModelCheckpoint

6.6 Hasil dan Evaluasi Model Feature Engineering

6.6.1 Performa Model

Split	Accuracy	Catatan
Train	99.91%	Hampir sempurna sehingga mengindikasikan overfitting
Validation	94.79%	Performa baik pada data validasi
Test	88.50%	Gap ~6% dari validasi

6.6.2 Metrik Tambahan

Metrik	Nilai	Interpretasi
Recall Fake (Test)	94.44%	Efektif menangkap gambar deepfake
Recall Real (Test)	82.62%	Lebih rendah dalam menangkap gambar Real

Temuan Kunci Feature Engineering

Kelebihan Model:

- Recall Fake 94.4% di test set mengindikasikan bahwa model efektif mendeteksi gambar deepfake

Kelemahan yang Teridentifikasi:

- Akurasi sebesar 99.91 % pada data Training yang mengindikasikan overfitting pada model
- Akurasi lebih rendah dibanding model baseline tanpa feature engineering pada test set
- Model tanpa feature engineering cenderung lebih baik dalam memprediksi gambar yang dikarenakan fitur yang dihasilkan terlalu spesifik dan malah menurunkan performa model.

7. A/B Testing: Model Tanpa vs Dengan Feature Engineering

A/B Testing dilakukan untuk menentukan secara empiris dan statistis apakah penambahan Feature Engineering (Sobel, Laplacian, HSV Saturation) memberikan dampak nyata terhadap performa model deteksi deepfake. Pengujian dilakukan pada test set yang identik menggunakan dua model yang telah dilatih secara independen.

7.1 Setup Eksperimen

Aspek	Model A (Tanpa FE)	Model B (Dengan FE)
Nama	Tanpa Feature Engineering	Dengan Feature Engineering
Input Shape	(160, 160, 3)	(160, 160, 6)
Augmentasi	RandomRotation, Zoom, Flip, GaussianBlur	RandomRotation, Zoom, Flip, GaussianBlur
Fitur Tambahan	—	Sobel Edge, Laplacian, HSV Saturation
Test Dataset	Identik (22.393 gambar)	Identik (22.393 gambar)

7.2 Hipotesis Pengujian

Formulasi Hipotesis
H_0 :Tidak ada perbedaan signifikan performa antara Model A (tanpa FE) dan Model B (dengan FE).
H_1 : Ada perbedaan signifikan performa antara Model A dan Model B.
Taraf Signifikansi: $\alpha = 0.05$

7.3 Metode Pengujian

Dua metode statistik digunakan secara bersamaan untuk memvalidasi temuan dari perspektif yang berbeda:

7.3.1 McNemar's Test

McNemar's Test adalah uji statistik yang dirancang khusus untuk membandingkan prediksi dua model berpasangan pada data yang sama. Uji ini menilai apakah pola kesalahan prediksi kedua model secara statistis berbeda.

- Berdasarkan tabel kontingensi 2x2: kedua benar (a), hanya A benar (b), hanya B benar (c), kedua salah (d)
- Chi-square statistic dihitung dari perbedaan sel b dan c

7.3.2 Bootstrap Confidence Interval (95%)

Bootstrap CI menghasilkan estimasi selang kepercayaan 95% untuk tiga metrik utama (Accuracy, F1-Score, AUC) melalui resampling 1000 kali. Ini memberikan perspektif "signifikansi praktis" yang melengkapi McNemar's Test.

- n_bootstrap = 1000 iterasi resampling dengan penggantian
- Interval dihitung menggunakan percentile method: [2.5%, 97.5%]
- Interpretasi: jika CI kedua model tidak overlap artinya terdapat perbedaan signifikan secara praktis

7.4 Tabel Perbandingan Metrik

Metrik	Model A (Tanpa FE)	Model B (Dengan FE)	Selisih (A-B)	Model Lebih Baik
Accuracy	89.83 %	88.51%	+1.32 %	Model A
AUC	95.99 %	95.51%	+ 0.44 %	Model A
F1-Score	89.37 %	87.83 %	+1.54 %	Model A

7.5 Hasil Uji Statistik

7.5.1 McNemar's Test

Parameter	Nilai
Chi-Square	38.0022
p-value	0.000000
Keputusan	Tolak H_0

Kesimpulan : Karena p-value McNemar's Test < 0.05, maka H_0 ditolak sehingga ada perbedaan signifikan secara statistis antara pola prediksi kedua model.

7.5.2 Bootstrap Confidence Interval

Ringkasan tabel Bootstrap CI (output aktual dari notebook):

Metrik	Model A Mean	CI 95% Model A	Model B Mean	CI 95% Model B	Overlap
--------	--------------	----------------	--------------	----------------	---------

Accuracy	0.8983	[0.8944 – 0.9023]	0.8851	[0.8811 – 0.8890]	Tidak Overlap
F1-Score	0.8937	[0.8894 – 0.8982]	0.8783	[0.8739 – 0.8827]	Tidak Overlap
AUC	0.9599	[0.9575 – 0.9621]	0.9551	[0.9526 – 0.9576]	Overlap

7.6 Ringkasan Hasil A/B Testing

Uji Statistik	Hasil	Kesimpulan
McNemar's Test	0.0000	Tolak H_0
Bootstrap CI Accuracy	CI Tidak Overlap	Signifikan
Bootstrap CI F1-Score	CI Tidak Overlap	Signifikan
Bootstrap CI AUC	CI Overlap	Tidak Signifikan

Interpretasi A/B Testing

- McNemar's Test mengkonfirmasi perbedaan prediksi signifikan secara statistik ($p \approx 0.000000 < 0.05$), dengan Chi-square statistic = 38.0022
- Bootstrap CI mengkonfirmasi perbedaan Accuracy dan F1-Score signifikan secara praktis (CI tidak overlap)
- AUC kedua model menunjukkan CI yang saling overlap, namun selisih mean tetap konsisten (A: 0.9599 vs B: 0.9551)
- Kombinasi kedua uji ini memberikan bukti kuat bahwa ****kedua model memiliki performa yang berbeda secara signifikan****
- Hal ini menyatakan bahwa Model A (Tanpa Feature Engineering) merupakan model yang lebih unggul dalam memprediksi citra Deepfake vs Real

8. Kesimpulan dan Rekomendasi Action Items

8.1 Ringkasan Temuan Keseluruhan

Seluruh tahapan analisis dari Data Wrangling hingga A/B Testing menghasilkan temuan yang saling terhubung dan dapat langsung ditindaklanjuti.

Tahapan	Temuan Kunci	Implikasi
Data Wrangling	Dataset berhasil digabungkan dan dibersihkan dari data duplikat dan seluruh data diresize ke 256 x 256 px	Dataset sudah siap untuk dianalisis dan dilakukan pelatihan model oleh tim AI Engineer.
EDA — BQ 1	Ketimpangan kelas terkonsentrasi di split Train (Fake 53,19% vs Real 46,81%)	Terapkan class weight pada loss function
EDA — BQ 2	Perbedaan brightness/contrast sangat kecil (Cohen's d < 0,2)	Normalisasi + augmentasi ColorJitter
EDA — BQ 3	Channel Green paling diskriminatif (Cohen's d = -0,042); arah artefak GAN konsisten di ketiga channel	Pertimbangkan Channel Attention
Feature Engineering	FE meningkatkan val acc ke 94.99% namun menurunkan test acc ke 87.62%	Overfitting perlu ditangani; regularisasi lebih kuat
A/B Testing	Model tanpa FE berperforma lebih baik di test set	Kompleksitas FE tidak sepadan untuk dataset ini

8.2 Rekomendasi Action Items untuk Tim AI Engineer

Rekomendasi 1: Gunakan Model Baseline (Tanpa FE) sebagai Production Model

Prioritas: TINGGI
Berdasarkan hasil A/B Testing, model tanpa Feature Engineering menunjukkan test set performance yang lebih baik dan lebih stabil. Hal ini dikarenakan kesederhanaan arsitektur mengurangi overfitting, inference lebih cepat (3-channel vs 6-channel), dan threshold lebih stabil antar set. Oleh karena itu, gunakan model tanpa Feature Engineering sebagai foundation untuk deployment

Rekomendasi 2: Terapkan Augmentasi Gambar saat Pelatihan

Prioritas: TINGGI

Temuan BQ 2 mengonfirmasi perbedaan distribusi brightness/contrast yang sistematis meski kecil. Oleh karena itu, diperlukan metode augmentasi gambar seperti ColorJittering (mengacak pencahayaan dan contrast). Tujuannya bukan merespons perbedaan yang besar, melainkan memastikan model tidak menghafal bias pencahayaan dataset sebagai sinyal pembeda.

Rekomendasi 3: Evaluasi Model dengan Metrik Komparatif

Karena kelas dataset seimbang, gunakan kombinasi metrik berikut untuk evaluasi model yang komprehensif:

Metrik	Fungsi	Target
Accuracy	Metrik utama (kelas seimbang)	> 85%
F1-Score (macro)	Konfirmasi keseimbangan precision-recall	> 0.85
ROC-AUC	Metrik ranking yang robust terhadap threshold	> 0.95
Recall (Fake)	Keberhasilan mendeteksi deepfake	> 85%

8.3 Catatan untuk Penelitian Lanjutan

- **Validasi lintas dataset:** Model dilatih pada data 2020–2026. Uji pada dataset deepfake sumber berbeda (khususnya generasi 2024–2026 yang menggunakan arsitektur GAN terbaru) untuk mengukur kemampuan generalisasi sebelum deployment publik.
- **Analisis berbasis frekuensi:** EDA ini berbasis piksel. Analisis FFT/DCT berpotensi mengungkap artefak GAN yang tidak terdeteksi di ruang piksel.
- **Explainability:** Integrasikan Grad-CAM atau LIME untuk memvisualisasikan area wajah yang paling berpengaruh pada prediksi sehingga meningkatkan kepercayaan pengguna dan nilai edukatif sistem DeepShield.

Kesimpulan Akhir
DeepShield telah berhasil membangun pipeline analisis data yang komprehensif dan menghasilkan model baseline dengan performa di atas target: Accuracy 89,83%, AUC-ROC 95,99% . Model ini siap menjadi fondasi deployment awal. Dengan penambahan augmentasi ColorJitter dan normalisasi per-channel yang tepat, performa model diproyeksikan dapat meningkat lebih lanjut pada iterasi berikutnya.

9. Daftar Pustaka

- Security Hero. (2023). 2023 state of deepfakes: Proliferation, targets, and cybersecurity challenges. <https://www.securityhero.io/state-of-deepfakes/>
- Guha Roy, S. (2025). Projections of synthetic media and deepfake proliferation. TechForensics Journal. <https://www.sciencedirect.com>
- Fortune. (2026). Corporate financial losses from deepfake fraud hit new highs. Fortune. <https://fortune.com>
- Diel, A., Lalgı, T., Schröter, I. C., MacDorman, K. F., Teufel, M., & Bäuerle, A. (2024). Human performance in detecting deepfakes: A systematic review and meta-analysis of 56 papers. Computers in Human Behavior Reports, 16, 100538. <https://doi.org/10.1016/j.chbr.2024.100538>
- Müller, N. M., & Choong, W. H. (2026). *Eroding trust in real speech: A large-scale study of human audio deepfake perception*. arXiv. <https://arxiv.org/abs/2605.26136>
- Kementerian Komunikasi dan Digital Republik Indonesia. (2025). Komdigi identifikasi 1.923 konten hoaks sepanjang tahun 2024 (Siaran Pers No. 08/HM-KKD/01/2025) [Siaran pers]. <https://www.komdigi.go.id/berita/siaran-pers/detail/komdigi-identifikasi-1923-konten-hoaks-sepanjang-tahun-2024>
- Irvan, R., & Setiawan, J. H. (2026). Criminalization policy of deepfake in Indonesian elections. Journal of Clinical Legal Studies, 5(1), 187-206. <https://cls.ubl.ac.id/index.php/jcls>
- Putri, N. A., Nurmasitha, N., & Neisya, N. L. (2025). Analisis pertanggungjawaban perdata terhadap penyalahgunaan teknologi artificial intelligence (deepfake). Rewang Rencang: Jurnal Hukum Lex Generalis, 6(12). <https://doi.org/10.56370/jhlg.v6i12.2019>
- Signicat. (2025, 20 Februari). Fraud attempts with deepfakes have increased by 2137% over the last three years [Siaran pers]. <https://www.signicat.com/press-releases/fraud-attempts-with-deepfakes-have-increased-by-2137-over-the-last-three-year>
- Diel, A., Teufel, M., & Bäuerle, A. (2024). Inability to detect deepfakes: Deepfake detection training improves detection accuracy, but increases emotional distress and reduces self-efficacy. OSF Preprints. <https://osf.io/4n3yp/>

Lampiran (Referensi Teknis)

A. Dataset Information

Parameter	Detail
Nama Dataset	Deepfake and Real Images + 4 Dataset Tambahan serupa (Kaggle)
Tahun Koleksi	2020 – 2026
Total Gambar	388.389 gambar (190.335 dataset awal + 198.054 dataset tambahan)
Total Gambar setelah Wrangling	371.076 gambar
Format	.jpeg
Resolusi Asli	Bervariasi (distandarisasi ke 256 x 256)
Label	Fake / Real (biner)
Split Ratio	~73% Train / ~21% Validation / ~6% Test

B. Tools dan Library yang Digunakan

Tool / Library	Penggunaan dalam Proyek
Python 3.x	Bahasa pemrograman utama
TensorFlow / Keras	Framework deep learning untuk training model
PyTorch / torchvision	Preprocessing dan transformasi gambar (data wrangling)
PIL / Pillow	Membaca, memproses, dan menganalisis gambar
NumPy	Operasi numerik dan ekstraksi fitur piksel
Pandas	Manipulasi data tabular dan export CSV
Matplotlib / Seaborn	Visualisasi distribusi dan analisis EDA
SciPy	Uji statistik Mann-Whitney U
Scikit-learn	Evaluasi model (confusion matrix, ROC curve, F1-score)
StatsModels	McNemar's Test untuk A/B testing
concurrent.futures	Pemrosesan paralel untuk ekstraksi fitur (ProcessPoolExecutor)
tqdm	Progress bar untuk monitoring proses panjang

C. Rumus Statistik yang Digunakan

Metrik	Formula / Deskripsi
--------	---------------------

Cohen's d	Cohen's d mengukur seberapa besar efek atau seberapa jauh perbedaan nyata antara rata-rata dua kelompok data. Rumusnya: $d = \frac{\bar{X}_A - \bar{X}_B}{s_{\text{pooled}}}$ Dengan: • $d < 0.2$ = sangat kecil • $d 0.2-0.5$ = kecil • $d 0.5-0.8$ = sedang • $d > 0.8$ = besar
Mann-Whitney U	Mann-Whitney U menguji perbedaan nilai tengah atau distribusi antara dua kelompok independen ketika data tidak berdistribusi normal. Rumusnya: $U_1 = n_1 n_2 + (n_1(n_1 + 1))/2 - R_1$ $U_2 = n_1 n_2 + (n_2(n_2 + 1))/2 - R_2$ $U = \min(U_1, U_2)$
G-Mean (Threshold)	G-Mean (Threshold) menentukan titik potong (<i>threshold</i>) paling optimal pada kurva ROC untuk menyeimbangkan akurasi deteksi kelas positif dan negatif pada data tidak seimbang (<i>imbalanced</i>): $\text{G-Mean} = \sqrt{\text{TPR} \times (1 - \text{FPR})}$ Digunakan untuk menemukan threshold optimal dari kurva ROC
Bootstrap CI	Bootstrap CI menentukan rentang selang kepercayaan parameter secara empiris melalui simulasi pengambilan sampel berulang dengan pengembalian tanpa bergantung pada asumsi distribusi. Rumusnya: $CI_{95\%} = [\text{percentile}(2.5\%), \text{percentile}(97.5\%)]$
McNemar's Chi-square	McNemar's Chi-square menguji signifikansi perubahan proporsi atau perbedaan respons sebelum dan sesudah perlakuan pada sampel yang sama (berpasangan).

	Rumusnya: $\chi^2 = \frac{(b - c - 1)^2}{b + c}$
--	--

D. Dokumentasi Pengerjaan Data Scientist

Dokumentasi	Tautan
Dataset bersih	https://www.kaggle.com/datasets/remonggkircop/deepfake-clean-final
Notebook Pengerjaan	https://github.com/PeterTaniwan/DeepShield-DeepFake-Image-Detection-Capstone-Project-Coding-Camp-2026/tree/main/Data%20Scientist
Dashboard Streamlit	https://deepshield-dashboard.streamlit.app/